



Famous Last Question

*Wie könnte man Segmentierung
und Objektwissen verbinden, um
die Figuren zu extrahieren?*


Welche Art von Objektwissen?





Modellbasierte Segmentierung

- Interaktive Suche
 - Markerbasierte WST
 - Region Growing
 - Kantenverfolgung
- Vollständige Suche
 - Template Matching
 - Hough Transformation





Modellbasierte Segmentierung

- Segmentierung: Generierung von Symbolen (Bedeutungsträgern) aus Pixeln.
- Modell: Erwartete Bedeutung

► Widerspruch!


Modellbasierte Segmentierung: Mixtur zwischen Segmentierung und Analyse. Mit Vorwissen über ein bestimmtes Objekt wird nach Instanzen gesucht


- Interaktive Suche: Benutzer gibt Vorwissen interaktiv ein
- Vollständige Suche: Instanzen eines Modells mit wenigen Parametern werden gesucht
- Iterative Suche: Instanzen eines Modells mit vielen Parametern werden gesucht.



Region Growing



- Flood Fill auf Grauwertbild für einen einzigen (vorgegebenen) Saatpunkt.
- **Homogenitätsbedingungen:**
 - Grauwertbereich
 - Grauwertschwankung
- **Annahmen und Ziel:**
 - Gebiet ist intern von größerer Homogenität als an den Grenzen.
 - Selektion eines einzigen Gebiets.
 - Homogenitätsverhältnisse an anderen Orten interessieren nicht.










Region Growing

- Probleme:
 - „Auslaufen“ der Regionen
 - zu kleine Regionen
 - Rauschanfälligkeit
 - Shading im Bild





Auslaufen von Regionen







Region Growing und Rauschunterdrückung

Rauschen führt zu Anfälligkeit der Methode

→ vorherige **Rauschunterdrückung** oder
Nachverarbeitung







Mehrfaches Region Growing



original




Zusammensetzung aus allen drei Segmenten



Region Growing

- interaktives, recht intuitives Werkzeug
 - Startpunktselektion sollte für „Datenexperten“ trivial sein
 - Homogenitätskriterium kann schwieriger zu bestimmen sein.
- geeignet, falls das gesuchte Objekt homogen ist und sich überall vom Hintergrund abhebt.
- „Auslaufen“ kann durch unterschiedliche Maßnahmen begrenzt werden.
- Grundsätzlich auch in 3-d anwendbar, aber weniger intuitiv, da Resultate nicht einfach visualisiert werden können.



Gezielte Kantensuche

- Resultat der Kantenfilter:
- Liste von Kantenpunktkandidaten
- **nicht alle Kandidaten** gehören zur gesuchten Regionengrenze.
- die Regionengrenze kann **Lücken** aufweisen.
- Strategien mit Nutzerinteraktion
 - Optimale Kantenzüge
 - Hough Transformation



Nur diese Kante ist gesucht



Optimale Kantenzüge (Pfadsuche)

Pixel sind Knoten in eines Graphen.


Benachbarte Pixel sind durch Kanten verbunden.

Knotenkosten spiegeln die Wahrscheinlichkeit wider, dass das betreffende Pixel zu einer Kante gehört

Gesuchter Kantenzug ist ein optimaler Pfad in diesem Graphen

Vorteil:



Globale Aspekte des Kantenzugs können eingebracht werden (z.B. Gesamtlänge des Kantenzugs)





Optimale Kantenzüge (Pfadsuche in Pixelgraph)


- Naheliegende Optimalitätskriterien:
 - Maximierung der Gradientenlänge (???)
 - Minimierung der Abweichungen von einer erwarteten Gradientenlänge
 - Minimierung der Pfadlänge
 - Minimierung der Richtungsänderungen
 - Minimierung der Grauwertänderungen





Live Wire


- Startpunkt liefert „Modellgradienten“
- Kriterien
 - wenig Abweichungen von der Länge des Modellgradienten
 - kurze Pfadlänge
- Methode
 - Dijkstra-Algorithmus zu allen möglichen Endpunkten
 - Pfad wird von gesetztem Endpunkt zurückverfolgt



Resultate



Startpunkt





Live Wire - Kantensuche als Pfadsuche

- Ist ein schnelles, intuitives Werkzeug zur interaktiven Segmentierung
- Eignet sich gut, wenn Kanten klar abgrenzbar sind, auch wenn die Gradientenstärke lokal variiert
- Kann sogar Lücken in Kantenzügen überbrücken (ist dann aber rauschanfällig)







Template Matching

Segmentierung durch vollständige Suche:


- Gezielte Suche nach einer vorgegebenen Form.
- Für jeden Ort im Bild wird ein Abstandsmaß zwischen Form und Bild berechnet.
- Der Ort, an dem das Maß am höchsten ist, ist die gesuchte Position des Objekts.
- Abstandsmaße zwischen Bild $f(x, y)$ und Template $t(x, y)$: z.B.
 - MAD: mean absolute difference: $MAD(x, y) = \frac{1}{MN} \cdot \sum_{xy} |f(x + m, y + n) - t(x, y)|$
 - Korrelationskoeffizient $cc(x, y)$




Template Matching




Template




Maximum ist im Mittelpunkt
der gesuchten Struktur.





$$-MAD(x, y)$$



Template Matching - Rauschen




Template T_{org}





Wegen der integrierenden Komponente ist
Template Matching unempfindlich gegenüber
Rauschen



Template Matching - Probleme




Template ($Rot[Torg, 15^\circ]$)




Match ist nicht perfekt: Werte der lokalen Maxima gleichen sich an.



$-MAD(x, y)$



Template Matching - Probleme



Template ($0.5 \cdot T_{org}$)




$-MAD(x, y)$


Falsch skalierte Grauwerte des Template:
Lokalen Maxima beginnen zu verschwinden.



Template Matching - Probleme



Template ($T_{org} - 120$)



$-MAD(x, y)$

Falscher Durchschnittsgrauwert: Lokale Maxima beginnen zu verschwinden.



Korrelationskoeffizient


- Der Korrelationskoeffizient zwischen zwei Funktionen f und g ist ein Wert zwischen 1 und -1 .
- Der Korrelationskoeffizient ist definiert als
$$c = \frac{\sigma(f, g)}{\sigma(f) \cdot \sigma(g)}$$

wobei $\sigma(f)$, $\sigma(g)$ die Standardabweichungen von f und g , sowie $\sigma(f, g)$ die Kovarianz zwischen f und g ist

- Der Korrelationskoeffizient ist
 - 1, falls es einen positiven Skalar s gibt, so dass $f=s \cdot g$.
 - -1 , falls es einen negativen Skalar s gibt, so dass $f=s \cdot g$.
 - 0, falls f und g voneinander linear unabhängig sind.
- Der Korrelationskoeffizient ist damit als Ähnlichkeitsmaß unempfindlich gegenüber Skalierungen und Mittelwertveränderungen des Template.



Template Matching mit Korrelationskoeffizient



Resultate der Korrelation mit optimalem, skalierten und geminderten Templatewerten



Korrelation durch FFT

Für $\mu_I = 0$ kann die Korrelation durch die Kovarianz abgeschätzt werden¹:

$$c(m, n) = \frac{\sigma(f, t)}{\sigma(f) \cdot \sigma(t)} = \frac{\sum_{i,j} (f(i+m, j+n) - \mu_f)(t(i, j) - \mu_T)}{\sigma(f) \cdot \sigma(T)}$$



¹bis auf einen von Standardabweichungen von Template und überdeckter Region abhängigen Skalierungsfaktor.


$$c_F(m, n) = \sum_{i,j} (f(i+m, j+n) - \mu_f) \cdot (t(i, j) - \mu_T) = \sum_{i,j} f(i+m, j+n) \cdot t(i, j)$$

$$FT(c_F(m, n)) = F(u, v) \cdot T^*(u, v)$$





Korrelation durch FFT







Resultate






Resultate





Template Matching

- ist ein schnelles, automatisches Segmentierungsverfahren
- eignet sich gut, wenn die Form des gesuchten Objekts wenig variabel ist
 - Verkehrszeichen, Warenzeichen, Piktogramme
- Skalierungs- und Rotationsabhängigkeit kann zusätzliche Strategien für schnelle Berechnung erfordern
- kann auch zur Suche nach Regions of Interest benutzt werden, wenn die Form (in Maßen) variiert



Anwendung: ROI-Suche bei der Lymphknotendetektion




Hough Transformation

Modellbasierte Suche:

- Modell einer Regionengrenze ist vorgegeben.
- Information über mögliche Kantenorte ist gegeben (z.B. durch Gradientenlänge).
- Zielsetzung: Orte finden, an denen Modell und Bild optimal übereinstimmt.

Hough-Transformation:

- Voting(Abstimmungs)-Mechanismus, bei dem jeder Ort in Abhängigkeit der lokalen Information für das Modell stimmt.
- entwickelt für Geraden, erweiterbar für beliebige Formen.



Hough Transformation (HT)

Suche von Geraden in einem Binärbild.


Geradenrepräsentation: $x \cos(\alpha) + y \sin(\alpha) - d = 0$


Hough-Transformation:

Suche alle Parameter (α, d) für Geraden, die durch einen Punkt (x_n, y_n) gehen

$$d(\alpha) = x_n \cos(\alpha) + y_n \sin(\alpha)$$



Der Raum, der durch (α, d) aufgespannt wird, heißt *Hough-Raum*.







Berechnung der HT

- Erzeugung eines Kantenbilds durch Schwellenwertsetzung auf Gradientenlängen.
- Diskretisierung des (α, d) -Raums (Zerlegung in *Akkumulatoren*)
- Für jeden Punkt x_n, y_n wird eine Kurve im (α, d) -Raum diskretisiert.
- Jeder Akkumulator wird inkrementiert, sobald eine Kurve durch in verläuft.
- Parameter von Linien im Ortsraum sind durch (α, d) -Kombinationen gegeben, deren Wert (Stimmenanzahl, votes) nach Ausführung der Transformation am höchsten sind.






Hough Transformation






Hough Transformation


Breite Kanten führen zu flacheren
Maxima im Hough-Raum





Hough Transformation in nicht-binären Bildern


Bei Gewichtung der Stimmanzahl durch die Kantenstärke lassen sich Kanten von Rauschen unterscheiden.






Hough Transformation für Kreise


- Kreisgleichung für Kreis mit Mittelpunkt (x_c, y_c) und Radius r : $(x - x_c)^2 + (y - y_c)^2 - r^2 = 0$.
- Falls der Radius bekannt ist, ist nur der Verschiebevektor (x_c, y_c) gesucht
 - Hough-Raum = Ortsraum
 - Um jeden Kantepunkt wird ein Kreis mit Radius r diskretisiert.
- Beschleunigung: Akkumulator wird nur in Distanz r in und entgegen der Gradientenrichtung inkrementiert.






Hough Transformation für Kreise






Hough Transformation

- Automatisches Verfahren, das Segmentränder und Teile von Segmenträndern findet
 - flexibler als Template Matching
 - kann aber Nachverarbeitung erfordern (Zusammensetzung von Randteilen)
- Das Voting-System ist interessant für Echtzeitanwendungen
 - Bereits eine Teilmenge der Stimmen erlaubt Vorhersagen auf das Endergebnis
 - Stimmabgabe kann gesteuert werden, so dass „wichtige“ Stimmen zuerst abgegeben werden.



Was sollten Sie gelernt haben?

- Rolle des Modellwissens bei der Segmentierung
- Methoden mit interaktivem Einbringen von Modellwissen
 - Welche Art von Modellwissen
 - Wo und warum erfolgreich
- Methoden, die eine vollständige Suche verwenden
 - Welche Art von Modellen
 - Voraussetzungen



Famous Last Question

Wo kommen die zusätzlichen lokalen Maxima her?

